

Detección de Enfermedad Renal Crónica con Machine Learning: el peso de los valores faltantes

Comparación de Regresión Logística, SVM, Random Forest y Red Neuronal sobre datos clínicos reales

Bethania Arami Avila Dominguez

Trabajo Práctico Integrador
Taller de Machine Learning – Proyecto II ML
Caso 3 · Dataset UCI ID 336
Septiembre 2026

1 Problema

La **enfermedad renal crónica (ERC)** afecta a ~9 % de la población mundial [2] y es **asintomática en etapas tempranas**: suele diagnosticarse tarde.

Objetivo: clasificar pacientes **con ERC (ckd = 1)** y **sin ERC (notckd = 0)** a partir de análisis de sangre/orina de rutina y antecedentes.

En tamizaje, el error más costoso es el **falso negativo** → métrica clave: **Recall** (y F1).

Pregunta del caso: *¿cómo afecta el tratamiento de los valores faltantes al desempeño final?*

2 Dataset

Chronic Kidney Disease – UCI ML Repository [1], Apollo Hospitals (India).

400

pacientes

250

ckd (62,5 %)

150

notckd (37,5 %)

24


variables (14 num. + 10 binarias)

10,5 %

celdas faltantes


158

filas completas (40 %)



Los faltantes **no son aleatorios**: un paciente con ERC tiene en promedio 3,6 datos faltantes y uno sano, 0,7. Entre las filas completas solo el 27 % es ckd.


3 Exploración



Dos variables ya separan casi por completo las clases.

- ERC: ↓ **hemoglobina**, **hematocrito**, **gravedad específica**; ↑ **creatinina**, **urea**, **albúmina**.
- Hipertensión, diabetes, anemia y edema aparecen **solo** en pacientes con ERC.
- Hay outliers clínicamente reales (creatinina de hasta 76 mg/dl) → se conservan.

4 Metodología




Todo el preprocesamiento se ajusta **solo con el entrenamiento** de cada fold → **sin data leakage**. Semilla fija (42) para que sea reproducible.

Modelo	Hiperparámetros explorados	Mejor configuración
Regresión Logística	$C \in \{0,01 \dots 100\}$, L1/L2, class_weight	$C = 10$, L2
SVM	lineal/RBF, $C \in \{0,1 \dots 100\}$, γ	RBF, $C = 10$, $\gamma = \text{scale}$
Random Forest	árboles, profundidad, hojas, max_features	200 árboles, sin límite
Red Neuronal (Keras)	capas (8) · (16, 8) · (32, 16); dropout 0/0,3	24 → 8 → 1, dropout 0,3


Red: ReLU + salida sigmoide, entropía cruzada binaria, Adam (lr = 0,003), batch 32, early stopping (paciencia 20).

5 Resultados sobre Test


Modelo	Accuracy	Precision	Recall	F1	AUC	F1 CV
Regresión Logística	0,975	1,000	0,960	0,980	0,999	0,997
SVM (RBF)	0,988	1,000	0,980	0,990	1,000	0,997
Random Forest	1,000	1,000	1,000	1,000	1,000	0,995
Red Neuronal	0,963	1,000	0,940	0,969	0,995	0,995



Matrices de confusión (Test). **Ningún falso positivo**; todos los errores son enfermos no detectados (FN: $2 \cdot 1 \cdot 0 \cdot 3$).




Curvas ROC sobre Test: **AUC ≥ 0,995** en los 4 modelos. Los modelos ordenan casi perfectamente a los pacientes; las diferencias aparecen solo en el umbral de 0,5.



Coefficientes de la Regresión Logística e importancia por permutación del RF: **hemo**, **sg**, **pcv**, **al**, **sc**, **htn**, **dm**, todas con sentido clínico.

6 ¿Y los valores faltantes?

Comparamos 6 estrategias con los mismos hiperparámetros (CV 5×2 sobre Training; se evalúa siempre sobre **todos** los pacientes).



Eliminar pacientes incompletos → **F1 0,81–0,92 · Recall 0,69–0,86**

Se pierde el 62 % del entrenamiento y la proporción de ckd cae de **62,5 % a 26,5 %**: los modelos dejan de detectar enfermos. Cualquier imputación (mediana, KNN, MICE) → **F1 ≥ 0,98**.

Un modelo que **solo sabe qué datos faltan** ya logra AUC = 0,86: la ausencia de datos es informativa (efecto del protocolo de registro) → cuidado con explotarla.

7 Discusión

- Clases casi separables: los 4 modelos obtienen $F1_{CV} \geq 0,99$, en línea con la literatura (RF 99,75 % [4]; SVM 98,5 % [5]).
- Las diferencias en Test son de **1 a 3 pacientes** (1 paciente = 1,25 pts de Accuracy): hay que leerlas con cautela.
- La red neuronal extrapola mal con outliers extremos (creatinina 32 → $P(\text{ckd}) \approx 0$); el RF es robusto. Brecha train–CV ≤ 0,005: sin sobreajuste.

8 Conclusiones

- La ERC se detecta con muy alta precisión usando **análisis de rutina**.
- Random Forest** fue el más adecuado: Recall = 1,00 (ningún enfermo sin detectar). La Regresión Logística es una alternativa más interpretable.
- El tratamiento de faltantes pesó más que la elección del modelo**: hay que conservar a todos los pacientes e imputar dentro del pipeline.
- Limitaciones**: 400 pacientes de un solo hospital; faltantes asociados a la clase; Test pequeño.
- Trabajo futuro**: validación externa, ajuste del umbral para priorizar el Recall, XGBoost, SHAP.

Referencias

- L. J. Rubini, P. Soundarapandian y P. Eswaran, "Chronic Kidney Disease," UCI ML Repository, 2015, doi: 10.24432/C5G020.
- KDIGO CKD Work Group, "KDIGO 2012 clinical practice guideline for the evaluation and management of CKD," *Kidney Int. Suppl.*, vol. 3, no. 1, pp. 1–150, 2013.
- J. Qin *et al.*, "A machine learning methodology for diagnosing chronic kidney disease," *IEEE Access*, vol. 8, pp. 20991–21002, 2020.
- H. Polat, H. Danaei Mehr y A. Cetin, "Diagnosis of chronic kidney disease based on SVM by feature selection methods," *J. Med. Syst.*, vol. 41, no. 4, art. 55, 2017.
- L. Breiman, "Random forests," *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, 2001.
- D. B. Rubin, "Inference and missing data," *Biometrika*, vol. 63, no. 3, pp. 581–592, 1976.